

LLM Uygulamalarının Kalitesini Nasıl Yükseltiriz?

Nazlı Dereli
Co-founder @ Raar AI



Gündem

- Değerlendirme nedir? LLM uygulamaları için neden önemlidir?
- Three Gulfs Models: Zorlukları sınıflandırma ve tanımlama
- Değerlendirme yaşam döngüsü: Analiz - Ölçüm - İyileştirme


Değerlendirme (LLM Evaluation)

Tanım: LLM uygulamasının kalitesini sistematik olarak ölçme

- Tek bir sayıdan daha fazlası
- Neden önemli?
 - Kullanıcılar için güvenli, tutarlı ve yararlı sonuçlar
 - Uygulamanın zaman içinde değişen kalitesini takip edebilme
 - Uygulamayı iyileştirme

Three Gulfs Model:

Zorlukları sınıflandırma ve tanımlama



Gulf of Comprehension


- Developer $\Leftrightarrow$ Data
- Çok çeşitli input datayı anlama

“Elimde tavuk ve brokoli var, ne yapabilirim?”

“Parti için havalı bir tatlı öner.”


- LLM’in bu input üzerindeki davranışını ve hata biçimlerini anlama

Zorluk: Her bir input ya da outputu manuel olarak inceleyemezsiniz.



Gulf of Specification

- Developer $\Leftrightarrow$ LLM Pipeline
- Niyeti LLM için açık ve kesin promptlara dönüştürme süreci




“Bana kolay bir tarif ver.”

- Malzemeleri kolay bulunan mı?
- Pişirmesi hızlı mı?
- Az adımlı mı?

Zorluk: Doğal dil belirsizdir. LLM’ler açık ve net bilgilere ihtiyaç duyar.

Gulf of Generalization

- Data $\Leftrightarrow$ LLM Pipeline
- LLM'in, promptlar açık olsa bile farklı inputlar karşısında tutarlı ve doğru davranmasını sağlama




“kolay bir tatlı” vs “gurmeler için vegan, düşük kalorili tatlı”


- Bu, temel modelin yeteneklerini iyi anlamayı, karmaşık görevleri daha küçük adımlara ayırmayı vb. gerektirir.

Zorluk: LLM'ler, daha önce genelleme yapamadıkları yeni veya alışılmadık inputlarda başarısız olabilir.

Değerlendirme Yaşam Döngüsü: Analiz - Ölçüm - İyileştirme



Hata Analizi



1. Başlangıç datasetini oluşturma

- Trace: Kullanıcı sorgusu ile başlayıp kullanıcıya gösterilen son sonuç ile biten LLM'in gerçekleştirdiği işlemler dizisinin tamamı
- Çeşitli hata türlerini kapsayan ve “teorik doygunluk” sağlayan ~100 trace
- Gerçek kullanıcı traceleri, sentetik traceler ya da ikisinin birleşimi

Sentetik Trace Oluşturma

- Boyut: bir kullanıcı sorgusunun farklı bileşenlerini kategorize etmemize yardım eder
 - **Görev:** Kullanıcının gerçekleştirmek istediği işlem türü
 - Tarif önerisi, eldeki malzemeye göre tarif, öğün planlama, diyet oluşturma, malzeme alternatifi isteme
 - **Persona:** Uygulamayı kullanan kullanıcı profili
 - Yeni başlayan ev kullanıcısı, profesyonel aşçı, diyet yapan kullanıcı, vegan/vejetaryen kullanıcı, öğrenci, alerjisi olan kullanıcı
 - **Senaryo:** Kullanıcının niyetini ne kadar açık ifade ettiği
 - Açık: “Tavuk ve patatesle 30 dakikada yapılacak fırın yemeği önerir misin?”
 - Belirsiz: “Akşama kolay bir şeyler öner”
 - Eksik Bilgi: “Tatlı yapacağım ama elimde fazla bir şey yok...”

- (Görev, Persona, Senaryo) Üçlüleri Üret:

Görev	Persona	Senaryo
Tarif önerisi	Vegan kullanıcı	Belirsiz
Eldeki malzemeye göre tarif	Yoğun çalışan	Açık
Fırınsız yemek	Öğrenci	Eksik Bilgi

- Üçlüden Doğal Dil Sorgusu Üret:

(Tarif önerisi, Vegan kullanıcı, Belirsiz)

"Akşam yemeği için vegan bir şeyler önerebilir misin?"

(Eldeki malzemeye göre tarif, Yoğun çalışan, Açık)

"Evde makarna, domates sosu ve peynir var. Ne yapabilirim?"

(Fırınsız yemek, Öğrenci, Eksik bilgi)


"Fırınım yok ama yemek yapmak istiyorum. Ne önerirsin?"

- Her adımdan sonra insan incelemesi:

Tekrar eden üçlüleri ve gerçekçi olmayan sorguları ayıklama

2. Okuma ve Etiketleme


- Grounded theory (temellendirilmiş kuram): nitel araştırmalardan gelen bir analiz yöntemi
- Açık kodlama: veride önemli görülen kısımlara kısa, açıklayıcı etiketler verilmesi



Trace id	Trace	Açık kodlu not
trace_001	Kullanıcı: Vegan bir akşam yemeği öner LLM: Tavuklu salata tarifi önerdi	Vegan isteğine rağmen et içeren tarif verildi
trace_002	Kullanıcı: Tatlı tarifine un alternatifi sordu LLM: Un alternatifi vermedi, tarif aynen döndü	Alerji kısıtı dikkate alınmadı
trace_003	Kullanıcı: 10 dakikada yapılacak yemek istedi LLM: 45 dakikalık fırın tarifi sundu	Süre sınırına uymayan öneri verildi


3. Hata Türlerini Gruplama

- Eksenel kodlama: açık kodlama sırasında ortaya çıkan hata türleri arasında ilişkiler kurma ve düzenleme süreci
- Açık kodları LLM'e vererek, gruplama önerileri alınabilir (ama mutlaka manuel gözden geçirilmeli!)




Trace id	Açık kodlu not	Eksenel tema	Alt kategori
trace_001	Vegan isteğine rağmen et içeren tarif verildi	Kullanıcı Kısıtlamalarının İhlali	Diyetsel kısıtlama (vegan, keto, düşük kalorili)
trace_002	Alerji kısıtı dikkate alınmadı	Kullanıcı Kısıtlamalarının İhlali	Sağlık temelli kısıtlama (alerji, intolerans)
trace_003	Süre sınırına uymayan öneri verildi	Kullanıcı Kısıtlamalarının İhlali	Süre kısıtlaması

4 & 5. Etiketleri Uygula & Tekrarla



Trace id	Açık kodlu not	Diyetsel kısıtlama	Sağlık temelli kısıtlama	Süre kısıtlaması
trace_001	Vegan isteğine rağmen et içeren tarif verildi	1	0	0
trace_002	Alerji kısıtı dikkate alınmadı	0	1	0
trace_003	Süre sınırına uymayan öneri verildi	0	0	1
trace_004	Laktozsuz, düşük kalorili ve fırınsız tarif isteyen kullanıcıya fırında cheesecake tarifi önerildi	1	1	0

Ölçüm



- **Spesifikasyon Hatası:** Talimatınız belirsiz veya eksik

Vegan tarif isteğine rağmen promptta yalnızca bitkisel içerikler kullanılması istenmediği için bal içeren bir tarif önermesi

Yapılacak: Öncelikle promptu düzeltin! Bu tür hatalar için değerlendirici oluşturmayın.

- **Genelleme Hatası:** LLM'in açık talimatları farklı inputlara doğru şekilde uygulayamaması

Açıkça fırın gerektirmeyen tarifler istenmesine rağmen bazı tariflerde bu araç kısıtlamasını ihlal etmesi

Yapılacak: Bu tür hatalar, otomatik değerlendiriciler için ideal adaylardır!

Amaç: Değerlendiricileri öncelikli olarak bu **Genelleme Hatalarını** izlemek üzere tasarlamak.

Otomatik Değerlendiriciler

- **Kod Tabanlı Değerlendiriciler:** Nesnel ve kurallara dayalı kontroller için uygundur.
 - Yapı kontrolü (JSON, SQL vs.)
 - Regex/string eşlemesi
 - Yapısal kısıtlamalar (3 madde içeren özet, 100 kelimelik cevap vs.)
 - LLM tarafından yapılan araç çağrıları



- **LLM-Hakemli Değerlendiriciler:** Öznel, ince ayar gerektiren değerlendirmeler için uygundur.
- Tonlama uygun muydu? Özet, kaynağa sadık mıydı? Yanıt yardım edici miydi?
- Outputu değerlendirmek için başka bir LLM kullanılır.
- Hata türü başına bir prompt—spesifik, dar kapsamlı, Pass/Fail
- Few-shot örnekler
- Yapılandırılmış output formatı—{reasoning: “1-2 cümlelik açıklama”, answer: “Pass” veya “Fail”}

Görev: Aşağıdaki tarif yanıtını, verilen kullanıcı profiline uygunluk açısından değerlendir.

Değerlendirme kriteri:

- **Fail:** Tarifin tonu, dili veya içeriği ilgili kullanıcı profilinin ihtiyaçlarına uymamaktadır.
- **Pass:** Tarifin tonu, dili ve içeriği ilgili kullanıcı profilinin beklentilerine uygundur.

Kullanıcı Profilleri:

- **Profesyonel Aşçı:** Teknik doğruluk, hassas ölçüler ve ileri düzey pişirme detayları bekler.
- **Yoğun Çalışan:** Hızlı, pratik, net talimatlar ister.
- **Sağlık Bilinçli:** Besin dengesi, sağlıklı malzemelere vurgu bekler.

Örnek 1:

Kullanıcı Profili: Profesyonel Aşçı

Model Input:

Malzemeler: Et, Yağ, Baharat

Hazırlanışı: 1. Etleri yağda pişirin. 2. Baharat ekleyin. Karıştırın.

Model Output:

```
{  
  "reasoning": "Tarif çok yüzeysel; etin türü, miktarı, pişirme süresi ve teknik detaylar eksik. Profesyonel aşçılar için yetersiz.",  
  "answer": "Fail"  
}....
```

İyileştirme

Düşük Çaba, Yüksek Etki


- Prompt'u netleştir, belirsizliği azalt
- 2-3 hedeflenmiş few-shot örneği ekle
- Rol tanımı kullan: “Dikkatli bir vergi danışmanısın...”
- “Adım adım düşün” örneği ekleyerek mantıksal başarıyı artır

Orta Düzey Müdahale

- **Görev ayrıştırma:** Büyük işlemi küçük adımlara böl
- **RAG ayarları:** Chunking, belge sayısı, ajan yapıları
- **Araç kullanımı:** Tool açıklama & parametreleri prompt içinde netleştir

İleri Stratejiler

- **Fine-tuning:** Yüzlerce etiketli örnek varsa
- **Prompt optimizasyonu:** A/B testi, DSPy ile şablon denemeleri
- **İnsan geri bildirim döngüsü:** Yüksek riskli görevlerde sürekli veri toplama





Kalite tesadüf
değildir.



Kaynakça

- <https://thenewstack.io/why-most-genai-projects-fail-only-1-in-3-make-it-to-production/>
- Shreya Shankar, Bhavya Chopra, Mawil Hasan, Stephen Lee, Björn Hartmann, Joseph M Hellerstein, Aditya G Parameswaran, and Eugene Wu. Steering semantic data processing with docwrangler. arXiv preprint arXiv:2504.14764, 2025.
- Janice M Morse. The significance of saturation, 1995.
- Anselm Strauss, Juliet Corbin, et al. Basics of qualitative research, volume 15. sage Newbury Park, CA, 1990.
- Barney Glaser and Anselm Strauss. Discovery of grounded theory: Strategies for qualitative research. Routledge, 2017.
- Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric Xing, et al. Judging llm-as-a-judge with mt-bench and chatbot arena. Advances in Neural Information Processing Systems, 36:46595–46623, 2023.
- Shreya Shankar, JD Zamfirescu-Pereira, Björn Hartmann, Aditya Parameswaran, and Ian Arawjo. Who validates the validators? aligning llm-assisted evaluation of llm outputs with human preferences. In Proceedings of the 37th Annual ACM Symposium on User Interface Software and Technology, pages 1–14, 2024d.

Teşekkürler!

İletişim:

nazli@raar.ai

<https://www.linkedin.com/in/nazlidereli/>

Sunum:

